Uzaktan Algılama Görüntülerinde Derin Öğrenme Tabanlı Sahne Sınıflandırma

Transfer Öğrenme Yaklaşımı · Faz 1 İlerleme Sunumu

Muhammed Çakıcı · 241230035

Uygulamalı Yapay Zeka Dersi · Dr. Öğr. Üyesi Hayri İncekara

Yapay Zeka ve Makine Öğrenmesi Bölümü, Konya Teknik Üniversitesi



Örnek görüntüler: NWPU-RESISC45 ve UC Merced

Problem: Uydu Görüntüsünden Sahneyi Tanımak



CNN modeli → harbor (liman)

- Görüntüye tek bir sahne etiketi verilir (çok sınıflı, denetimli sınıflandırma).
- Kullanım: şehir planlama, arazi kullanım haritası, çevre izleme, afet tespiti.
- Elle etiketleme yavaş ve pahalı; otomatik sınıflandırma gerekli.

Zorluk: farklı sınıflar birbirine çok benziyor



dense residential



medium residential



sparse residential

Projenin amacı

2 veri seti × 3 model: transfer öğrenme (ResNet18, EfficientNet-B0) ile sıfırdan eğitilen CNN'i karşılaştırmak.

Kullanılan Veri Setleri

UC Merced Land Use

21 sınıf **2.100** görüntü

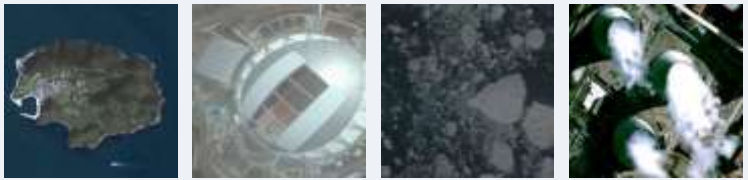


- Her sınıfta 100 görüntü · 256×256 · RGB · .tif
- ≈0,3 m/piksel · ABD (USGS) hava fotoğrafları
- Yang & Newsam (2010)

kaggle.com/…/uc-merced-land-use-dataset

NWPU-RESISC45

45 sınıf **31.500** görüntü



- Her sınıfta 700 görüntü · 256×256 · RGB · .jpg
- 0,2–30 m/piksel · 100+ ülke, Google Earth
- Cheng, Han & Lu (2017)

kaggle.com/…/nwpuresisc45

Veri Analizi: Ne Bulduk?

Tam dengeli
Her sınıfta eşit görüntü (100 / 700)

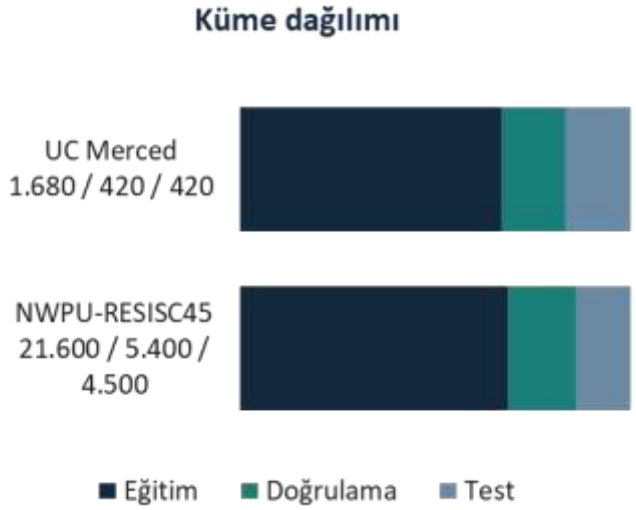
Eksik veri yok
Tüm dosyalar açılıyor, bozuk dosya yok

Etiketli
Etiket = klasör adı (21 / 45 sınıf)

Renkli (RGB)
3 kanal, 8 bit; grayscale yok

Boyut farkı
UC Merced'de 44 görüntü 256×256 değil

Benzer sınıflar
Ör. dense / medium / sparse residential



UCM: %70 / %10 / %20 bölündü.
NWPU: hazır test kümesi + eğitimin %20'si doğrulama.

Ön İşleme Adımları

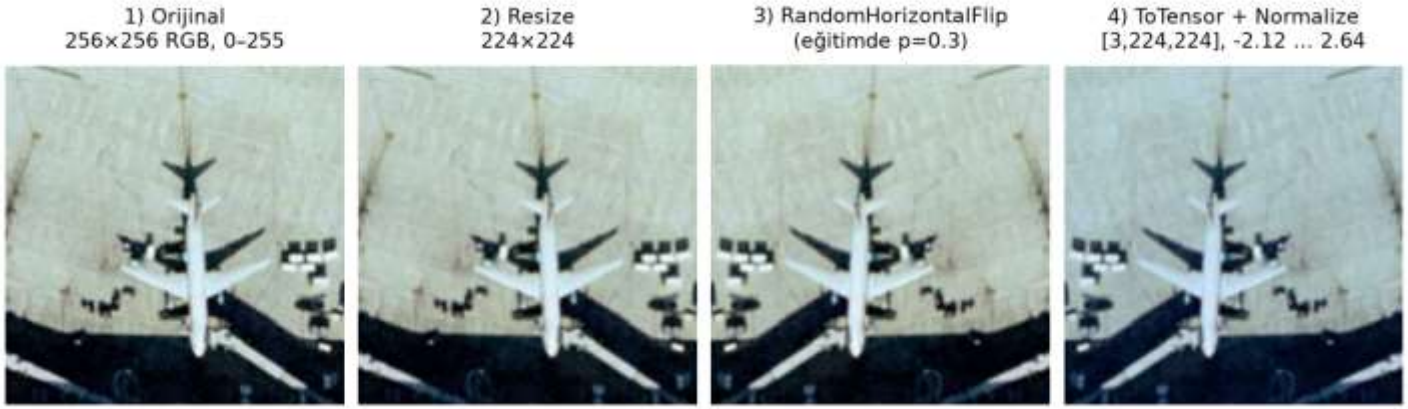
1 Bölme
split-folders
seed = 42

2 Boyutlandırma
Resize
224 × 224

3 Veri artırma
Yatay çevirme p=0.3
(sadece eğitim)

4 Normalizasyon
ToTensor +
ImageNet ort./std

5 DataLoader
batch = 16
eğitimde karıştırma



Literatür Taraması

Çalışma	Veri seti	Yöntem	Sonuç (doğruluk)
Yang & Newsam (2010)	UC Merced	El yapımı öznitelik (BoVW) + SVM	≈ %77,7
Hu vd. (2015)	UC Merced	Ön eğitimli CNN öznitelikleri (transfer)	%96,9
Cheng, Han & Lu (2017)	NWPU	İnce ayarlı VGG-16	%90,4 (eğitim %20)
Cheng vd. (2018)	UCM, NWPU	D-CNN: CNN + metrik öğrenme	UCM %98,9 · NWPU %91,9
Yu vd. (2020)	UCM, NWPU	Hafif MobileNetV2 + bilinear füzyon	UCM %99,0 · NWPU %94,1

Ortak sonuç: ImageNet'te ön eğitilmiş CNN + ince ayar en başarılı yaklaşım (UCM %98–99, NWPU %92–94). El yapımı yöntemler ≈ %77'de kalıyor. **Eksik:** basit CNN ile hafif modern modellerin aynı koşullarda karşılaştırması az – bu proje bunu yapıyor.

Seçilen Modeller ve Yöntem



Kendi CNN modelim
68 bin parametre, hepsi eğitiliyor
Daha az uygun model (baseline)

ResNet18
11,2 M parametre · eğitilen: 23 bin
Transfer öğrenme, omurga donuk

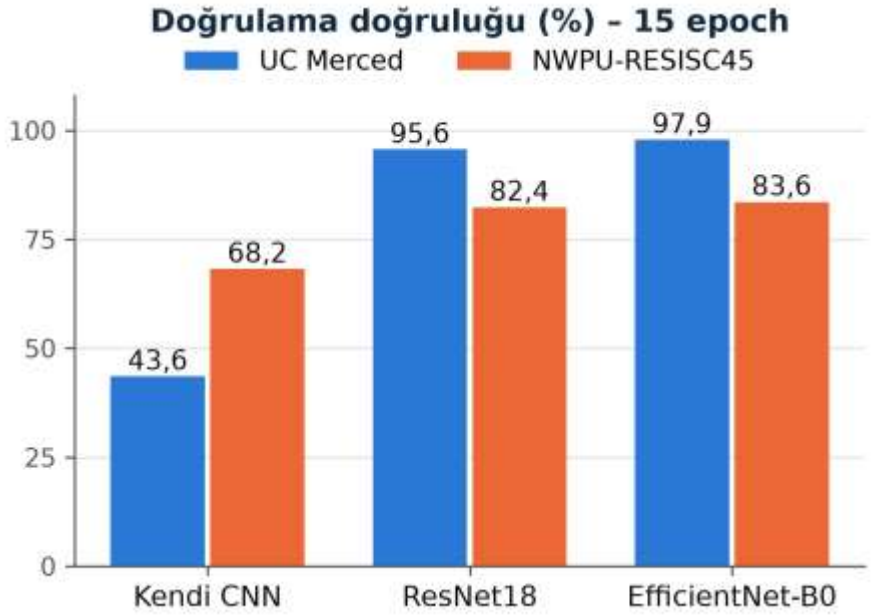
EfficientNet-B0
4,0 M parametre · eğitilen: 58 bin
Transfer öğrenme, omurga donuk

Eğitim ayarları
CrossEntropyLoss · Adam (lr = 0,001) · batch 16 · 15 epoch · Google Colab A100 GPU

Değerlendirme metrikleri
Accuracy · Precision · Recall · F1-score · Karışıklık matrisi

Faz 1 Durumu ve İlk Sonuçlar

- ✓ Veri setleri bulundu ve indirildi
- ✓ Veri analizi ve görselleştirme
- ✓ Ön işleme ve veri bölme
- ✓ Literatür taraması (5 çalışma)
- ✓ Model seçimi (3 model)
- \+ Önden: 6 model 15 epoch eğitildi



Doğrulama (validasyon) sonucudur, test sonucu değildir. Transfer öğrenme iki veri setinde de açık ara önde.

Karşılaşılan Problemler ve Faz 2 Planı

Problem → Çözüm

Veri setleri bölünmüş gelmedi
→ split-folders ile bölündü

UCM'de 44 görüntü farklı boyutta
→ Resize ile hepsi 224×224 yapıldı

Mac'te eğitim çok yavaş
→ Google Colab A100 GPU kullanıldı

Faz 2 planı

1. Eğitilen 6 modelin test kümesinde değerlendirilmesi
2. Accuracy, precision, recall, F1 ve karışıklık matrisi
3. Sonuçların grafiklerle görselleştirilmesi
4. Literatürle karşılaştırma ve makale formatında rapor

Teşekkürler

github.com/muhammedCakici/uzaktan-algilama-sahne-siniflandirma